Aplicación del modelo RBF multicuádrico a datos reales de pirólisis catalítica de biochar: depuración del dataset, extensión a variables mixtas mediante distancia de Gower, y resultados para H_2

Informe técnico

13 de agosto de 2026

Resumen

Este informe documenta la aplicación del modelo de aproximación RBF multicuádrico con selección *greedy* de centros y búsqueda de hiperparámetros por Latin Hypercube Sampling (desarrollado y validado previamente sobre datos sintéticos) a un conjunto de datos experimentales reales de pirólisis catalítica de biochar. Se documentan: (i) el proceso de depuración y reorganización del dataset original, incluyendo varios hallazgos relevantes sobre la naturaleza real de las variables (una variable de entrada no documentada inicialmente, una colinealidad perfecta entre dos columnas, y la identificación de tres columnas que resultáron ser variables de salida en lugar de entrada); (ii) una extensión metodológica necesaria para incorporar dos variables de entrada categóricas (nominales) mediante una distancia compuesta análoga al coeficiente de similitud de Gower (Gower, 1971); y (iii) los resultados de aplicar el modelo extendido a la predicción de la fracción molar de H_2 en el gas de síntesis. Se cierra con una discusión sobre la sensibilidad observada de los hiperparámetros del modelo frente a la notable estabilidad del RMSE-LOOCV resultante, conectada con resultados análogos –aunque en un contexto metodológicamente distinto– de la literatura de colocación RBF para ecuaciones diferenciales parciales.

Índice

1. Introducción **2**

2. El dataset original: estructura y hallazgos del análisis exploratorio **2**
2.1. Estructura del archivo entregado 2
2.2. Diseño experimental subyacente 3
2.3. Hallazgo 1: una variable de entrada no documentada 3
2.4. Hallazgo 2: colinealidad perfecta entre dos columnas 3
2.5. Hallazgo 3: columnas puramente derivadas 3
2.6. Hallazgo 4 (el más relevante): tres columnas son en realidad SALIDAS 4
2.7. Hallazgo 5: los cuatro gases son un dato composicional 4
2.8. Reorganización del dataset 4

3. Reformulación del problema de modelado **4**
3.1. Variables de entrada (6) 4
3.2. Variables de salida y estrategia composicional 4
3.2.1. Qué gas derivar 5

4. Extensión metodológica: distancia mixta tipo Gower **5**
4.1. El problema: dos entradas son categóricas . . . 5
4.2. El coeficiente de similitud de Gower . . . 5
4.3. Adaptación al núcleo multicuádrico . . . 6
4.4. Cola polinómica extendida . . . 6
4.5. Extensión de la búsqueda de hiperparámetros . . . 6

5. Aplicación a H_2: refinamiento y resultado final **7**
5.1. Primera corrida y hiperparámetros pegados al borde . . . 7
5.2. Refinamiento de los rangos . . . 7
5.3. Modelo final . . . 7
5.4. Dependencia parcial e interpretación fisicoquímica . . . 9

6. Discusión: sensibilidad de hiperparámetros vs. estabilidad del LOOCV **10**
6.1. La observación empírica . . . 10
6.2. Conexión con la literatura de colocación RBF para EDPs . . . 10
6.3. El comentario del usuario: experiencia previa en colocación RBF para EDPs . . . 10
6.4. Síntesis y diferencias importantes a señalar . . . 11

7. Limitaciones y próximos pasos **12**

8. Conclusiones **12**

1. Introducción

En un trabajo previo se diseñó, implementó y validó (sobre datos sintéticos con estructura controlada) un modelo de aproximación mediante funciones de base radial (RBF) con núcleo multicuádrico $\phi(r) = \sqrt{r^2 + c^2}$, incorporando: estandarización de variables, regularización de Tikhonov, selección *greedy* de centros guiada por validación cruzada *leave-one-out* (LOOCV) calculada de forma analítica mediante la fórmula de Rippa/Allen, y búsqueda de hiperparámetros mediante Latin Hypercube Sampling (LHS) en lugar de una grilla regular.

Este informe documenta la primera aplicación de ese modelo a un conjunto de datos experimentales reales: un ensayo de pirólisis catalítica de biochar, con $N = 83$ observaciones. A diferencia del caso sintético original –en el que las cinco variables independientes eran continuas– este dataset incluye dos variables de entrada **categóricas** (nominales, sin orden): el origen de la biomasa y el tipo de catalizador. Esto obligó a una extensión metodológica del modelo, documentada en la Sección 4.

Antes de llegar a esa extensión, sin embargo, una parte sustancial del trabajo consistió en depurar y reinterpretar correctamente el dataset original, cuya estructura contenía varias ambigüedades no triviales. Esa depuración se documenta en la Sección 2, porque varias de sus conclusiones determinan directamente cómo se planteó el problema de modelado.

2. El dataset original: estructura y hallazgos del análisis exploratorio

2.1. Estructura del archivo entregado

El archivo original (`05_Raw_Original_Dataset_Reference.xlsx`) contenía 83 filas y 15 columnas, agrupadas por el propio archivo en tres encabezados: *"ENTRADAS"* (ORIGEN, CAT, CARGA %, TR, N2), *"OBTENIDAS POR MEDICIÓN Y TGA"* (PERDIDA AL FUEGO, % Sólido, CENIZA), y *"SALIDAS"* (T, H2, CO, CH4, CO2, H2/CO, PERDIDA+CENIZA). El

usuario indicó inicialmente que las variables independientes eran ORIGEN, CAT, TR, N2, PERDIDA AL FUEGO, %Sólido, CENIZA y T (esta última mal etiquetada como "salida" en el archivo original), y que las variables dependientes eran H2, CO, CH4 y CO2.

2.2. Diseño experimental subyacente

El análisis exploratorio reveló un diseño experimental balanceado: ORIGEN (amazonas/cimitarra/maceo) y CAT (CaO/MgO/No CAT) forman una grilla $3 \times 3 = 9$ combinaciones, cada una con 9–10 réplicas (Tabla 1). Además, T y TR resultaron tomar únicamente 3 valores discretos cada una (400/600/800 °C y 0.25/0.5/1.0, respectivamente) por diseño experimental, mientras que N2 y CARGA % varían de forma más continua.

Cuadro 1: Combinaciones ORIGEN × CAT y número de réplicas.

ORIGEN	CAT	n
amazonas	CaO	9
amazonas	MgO	9
amazonas	No CAT	9
cimitarra	CaO	10
cimitarra	MgO	9
cimitarra	No CAT	9
maceo	CaO	10
maceo	MgO	9
maceo	No CAT	9

2.3. Hallazgo 1: una variable de entrada no documentada

La columna `CARGA %` (valores 0, 0.05, 0.10) apareció en el archivo sin haber sido mencionada como variable independiente. Un detalle llamó la atención: incluso las filas con `CAT="No CAT"` (sin catalizador) presentaban `CARGA %`> 0 en algunos casos –es decir, no se trata simplemente de la fracción de catalizador cargado, que sería idénticamente cero sin catalizador. Consultado el usuario, se confirmó que `CARGA %` es, en efecto, una variable de entrada legítima adicional, independiente de la anterior duda.

2.4. Hallazgo 2: colinealidad perfecta entre dos columnas

Se encontró que `CENIZA` + `PERDIDA AL FUEGO` = 1 de forma **exacta** en las 83 filas (correlación = −1,000; diferencia máxima respecto a la columna de referencia `PERDIDA+CENIZA`, que resultó ser idénticamente 1, fue cero a precisión de máquina). Ambas columnas codifican, por tanto, la misma información: una es uno menos la otra. Se decidió retener únicamente `CENIZA` como variable independiente (en el sentido estadístico, no de entrada del modelo – ver Hallazgo 4) junto con `% Sólido`, descartando `PERDIDA AL FUEGO` por ser enteramente redundante.

2.5. Hallazgo 3: columnas puramente derivadas

Se verificó que `H2/CO` = H2 ÷ CO exactamente (diferencia máxima = 0) y que `PERDIDA+CENIZA` = PERDIDA AL FUEGO + CENIZA exactamente. Ambas son columnas de referencia calculadas a partir de otras ya presentes en la tabla, sin información independiente: no se usan como entrada ni como salida separada del modelo.

2.6. Hallazgo 4 (el más relevante): tres columnas son en realidad SALIDAS

El agrupamiento del propio archivo original ya sugería algo: PERDIDA AL FUEGO, % Sólido y CENIZA no estaban bajo el encabezado "ENTRADAS", sino bajo un encabezado separado, "OBTENIDAS POR MEDICIÓN Y TGA". Un análisis de correlación aportó evidencia estadística concreta: `% Sólido` correlaciona con `T` en $r = -0{,}60$ (bastante fuerte). Esa correlación tiene una explicación física inmediata **solo** si `% Sólido` es el rendimiento de sólido/biochar de *ese* experimento (a mayor temperatura de pirólisis, más devolatilización, menos sólido remanente) – un fenómeno bien conocido en pirólisis. Si, en cambio, `% Sólido` fuera una caracterización de la biomasa *cruda* (antes de cualquier tratamiento térmico), no habría razón para que correlacionara con la temperatura del proceso.

Puesto en conocimiento de esta evidencia, el usuario confirmó: PERDIDA AL FUEGO, % Sólido y CENIZA se miden **después** de la pirólisis – caracterizan el sólido/biochar resultante, no la biomasa de partida. Son, por tanto, variables de **salida**, no de entrada. Usarlas como entrada para predecir la composición de gas habría sido una fuga de información (usar el resultado de un experimento para "predecir" otro resultado del mismo experimento), además de inutilizable en la práctica: esas características no se conocen antes de correr el experimento.

Esta corrección cambia sustancialmente el problema de modelado: en lugar de 4 variables de salida (los gases) y 8 de entrada, el problema quedó planteado con **6 variables de entrada** y **7 columnas de salida** (con redundancia entre dos de ellas, ver Hallazgo 2).

2.7. Hallazgo 5: los cuatro gases son un dato composicional

Se verificó que H2+CO+CH4+CO2 = 1 exactamente en las 83 filas (desviación estándar del orden de 10^{-17}, es decir, precisión de máquina). Los cuatro gases no son cuatro variables independientes sino una composición con 3 grados de libertad: conocidos tres de los cuatro valores, el cuarto queda determinado exactamente. Esto tiene una consecuencia directa sobre la estrategia de modelado, discutida en la Sección 3.2.

2.8. Reorganización del dataset

Con base en estos hallazgos, se entregó al usuario un archivo Excel reorganizado (`dataset_biochar_reorgan`) con las columnas agrupadas y coloreadas por bloque (entradas; salidas – gas; salidas – sólido; referencia/derivadas), columnas de verificación calculadas por fórmula (nunca valores fijos) confirmando ambas restricciones exactas encontradas, y comentarios documentándo cada decisión metodológica directamente en los encabezados correspondientes.

3. Reformulación del problema de modelado

3.1. Variables de entrada (6)

- **ORIGEN** – categórica, 3 niveles (amazonas, cimitarra, maceo)
- **CAT** – categórica, 3 niveles (CaO, MgO, No CAT)
- **CARGA %**, **TR**, **N2**, **T** – continuas

3.2. Variables de salida y estrategia composicional

De las 7 columnas de salida disponibles (H2, CO, CH4, CO2, CENIZA, % Sólido, PERDIDA AL FUEGO), se descarta PERDIDA AL FUEGO por redundante (Hallazgo 2), quedando 6 columnas de las cuales 5 son independientes: 3 grados de libertad en los gases (Hallazgo 5) más CENIZA y % Sólido.

Para los gases, se optó por modelar 3 de los 4 directamente vía RBF y derivar el cuarto por resta ($z_4 = 1 - z_1 - z_2 - z_3$), garantizando así que cualquier predicción nueva satisfaga exactamente la restricción composicional –a diferencia de modelar los 4 independientemente y normalizar al final, o de una transformación log-ratio (Aitchison), que se descartaron por mayor complejidad de implementación e interpretación sin una ganancia clara para este caso.

3.2.1. Qué gas derivar

Para decidir cuál de los cuatro gases conviene derivar (en lugar de modelar directamente), se realizó un diagnóstico rápido: regresión lineal múltiple (entradas continuas estandarizadas + categóricas *one-hot*) con validación cruzada de 5 particiones, como proxy económico de qué tan predecible es cada gas desde las entradas (Tabla 2).

Cuadro 2: Diagnóstico de predictibilidad lineal (proxy) por gas.

Gas	R^2 CV (lineal)	Rango	Desv. estándar
H2	0.925	0.009–0.378	0.116
CO2	0.828	0.044–0.551	0.131
CH4	0.596	0.192–0.428	0.045
CO	**0.367**	0.100–0.371	0.061

CO resultó, por amplio margen, el más difícil de explicar linealmente desde las entradas disponibles. Se decidió modelar H2, CH4 y CO2 directamente vía RBF, y derivar CO = 1−H2−CH4−CO2. El razonamiento es doble: (i) al ser CO el más ruidoso/difícil de ajustar directamente, derivarlo aprovecha la restricción de cierre composicional para "corregirlo" con la información de los otros tres, en lugar de depender de un ajuste directo potencialmente inestable; (ii) el radio H2/CO, de interés práctico según el archivo original, sigue siendo perfectamente calculable con el CO derivado. Se advierte, no obstante, que este diagnóstico usa un modelo **lineal**; una vez el RBF (no lineal) esté ajustado sobre los 4 gases, conviene revisar empíricamente si esta elección se mantiene.

Quedan, en definitiva, **5 modelos RBF independientes** por ajustar: H2, CH4, CO2, CENIZA y % Sólido. Este informe documenta el primero de ellos (H2) en detalle, como plantilla para los restantes.

4. Extensión metodológica: distancia mixta tipo Gower

4.1. El problema: dos entradas son categóricas

Todo el modelo RBF descansa en una distancia euclídea $r = \|\mathbf{x} - \mathbf{x}'\|$ con sentido físico: dos valores de temperatura cercanos (p.ej. 450 °C y 500 °C) deben producir una r chica. ORIGEN y CAT son variables **nominales**: no existe ningún sentido en el que "zeolita" esté más cerca de un catalizador que de otro. Codificar las categorías como enteros arbitrarios (CaO= 1, MgO= 2, No CAT= 3) le impondría al modelo una estructura ordinal inexistente –el modelo "creería" que el catalizador 1 está más cerca del 2 que del 3, sin que eso signifique nada.

4.2. El coeficiente de similitud de Gower

Gower (1971) [1] propuso un coeficiente general de similitud para conjuntos de datos con variables de tipo mixto (continuas, ordinales, binarias y nominales), pensado originalmente

para taxonomía numérica. Su idea central es promediar, sobre las p variables disponibles, una disimilitud calculada variable por variable:

$$d(\mathbf{x}, \mathbf{x}') = \frac{1}{p} \sum_{k=1}^{p} d_k(x_k, x'_k),$$

donde d_k se define según el tipo de la variable k:

- Si k es continua: $d_k(x_k, x'_k) = |x_k - x'_k|/R_k$, con R_k el rango observado de la variable (normalización a $[0, 1]$).
- Si k es nominal (nuestro caso): $d_k(x_k, x'_k) = 0$ si $x_k = x'_k$, y 1 en caso contrario ("*simple matching*").

Gower demostró que la matriz de similitudes resultante es semidefinida positiva (salvo, posiblemente, en presencia de datos faltantes), lo cual es relevante porque garantiza que d admite una representación euclídea –una propiedad deseable para cualquier distancia que se use dentro de un núcleo como el multicuádrico. Esta construcción es, hoy, el punto de partida estándar en la literatura de análisis de conglomerados y similitud para datos de tipo mixto [2].

4.3. Adaptación al núcleo multicuádrico

La multicuádrica $\phi(r) = \sqrt{r^2 + c^2}$ requiere una distancia (o, equivalentemente, una distancia *al cuadrado* r^2, que es la cantidad que efectivamente se necesita para evaluar ϕ). Se adapta la idea de Gower –separar la disimilitud por bloques de variables, según su tipo– pero en la versión "distancia al cuadrado" (para insertarla directamente en el núcleo) y reemplazando el promedio con pesos fijos $1/p$ por **pesos ajustables** w_m, uno por cada variable categórica, tratados como hiperparámetros del modelo:

$$r^2(\mathbf{x}, \mathbf{x}') = \underbrace{\|\tilde{\mathbf{x}}_{\text{cont}} - \tilde{\mathbf{x}}'_{\text{cont}}\|^2}_{\text{bloque continuo, z-score}} + \sum_{m=1}^{k} w_m \cdot \mathbb{1}\left[\text{cat}_m \neq \text{cat}'_m\right]$$

donde $\tilde{\mathbf{x}}_{\text{cont}}$ es el bloque de variables continuas ya estandarizado (igual que en el caso puramente continuo), y la suma corre sobre las $k = 2$ variables categóricas (ORIGEN, CAT). Si dos puntos coinciden en una variable categórica, esa variable no aporta nada a la distancia; si no coinciden, aporta exactamente w_m –el peso actúa como "cuánta distancia (en las mismas unidades que el bloque continuo estandarizado) representa un cambio de categoría en esa variable".

A diferencia del coeficiente de Gower original –pensado para medir similitud descriptivamente, con pesos fijados de antemano por el analista– aquí los pesos w_m se **aprenden de los datos**, junto con c y λ, minimizando el mismo criterio LOOCV usado para todas las demás decisiones estructurales del modelo (ver discusión de los dos niveles de función objetivo en el informe metodológico previo).

4.4. Cola polinómica extendida

La cola polinómica (Sección 2.2 del informe metodológico previo) se extiende con columnas *dummy one-hot* (todas las categorías, sin omitir ninguna) de cada variable categórica, además de la constante y los términos lineales en las variables continuas. Esto permite capturar el efecto principal de cada categoría sobre la tendencia global, independiente de su rol en la distancia radial.

4.5. Extensión de la búsqueda de hiperparámetros

Con $k = 2$ variables categóricas, el espacio de búsqueda pasa de dimensión 2 (c, λ) a dimensión $2 + k = 4$ $(c, \lambda, w_{\text{ORIGEN}}, w_{\text{CAT}})$. El muestreo mediante Latin Hypercube Sampling

(Sección 5 del informe metodológico previo) se generaliza de forma directa a esta dimensión mayor –es, de hecho, precisamente en dimensiones más altas donde LHS aventaja más claramente a un grid regular (Bergstra & Bengio, 2012 [3]): un grid con la misma resolución por eje que en el caso 2D requeriría, en dimensión 4, la cuarta potencia de evaluaciones.

5. Aplicación a H_2: refinamiento y resultado final

5.1. Primera corrida y hiperparámetros pegados al borde

Una primera corrida exploratoria (rangos $c \in (0{,}1, 10)$, $\lambda \in (10^{-6}, 1)$, $w_m \in (0{,}01, 100)$, 150 puntos LHS) arrojó $c = 0{,}156$, $\lambda = 2{,}02 \times 10^{-6}$ y $w_{\text{ORIGEN}} = 0{,}023$ –los tres sospechosamente cerca de sus respectivos bordes inferiores (posiciones relativas en escala logarítmica de 19 %, 5 % y 9 % del rango, respectivamente). Esto es una señal de alerta estándar en búsqueda de hiperparámetros: si el óptimo encontrado está en el borde del rango explorado, no se puede descartar que el verdadero óptimo esté fuera de ese rango.

5.2. Refinamiento de los rangos

Se ampliaron los tres rangos hacia los bordes donde se detectó el problema, y se repitió la búsqueda con presupuestos crecientes y semillas distintas, para evaluar tanto la posición del óptimo como la **estabilidad** del resultado entre corridas (Tabla 3).

Cuadro 3: Evolución de la búsqueda de hiperparámetros para H2 a través de tres corridas de refinamiento.

Corrida	Presup.	c	λ	w_{ORIGEN}	w_{CAT}	RMSE-LOOCV
1 (rangos iniciales)	150	0.156	$2{,}0 \times 10^{-6}$	0.023	9.33	0.01712
2 (rangos ampliados)	400	0.043	0.356	5.38	6.90	0.01688
3 (rangos amp., semilla distinta)	300	0.064	0.312	1.28	4.50	0.01690
4 (final, mayor presupuesto)	500	0.081	0.324	1.28	5.00	0.01698

Dos observaciones destacan de la Tabla 3. Primero, λ se estabilizó alrededor de 0,3 en las corridas 2–4 (tras ampliar su rango hacia arriba), confirmando que su valor inicial cercano al borde era, efectivamente, un artefacto de un rango demasiado angosto y no un óptimo genuino en el límite. Segundo –y más notable–, **los hiperparámetros varían sustancialmente entre las corridas 2, 3 y 4 (p.ej. w_{ORIGEN} entre 1.28 y 5.38), mientras que el RMSE-LOOCV resultante permanece casi idéntico** (0.01688–0.01698, una variación menor al 1 %). Esta observación se retoma con detalle en la Sección 6.

5.3. Modelo final

Se adoptó como definitivo el resultado de la corrida 4 (mayor presupuesto, 500 puntos LHS): $c = 0{,}0806$, $\lambda = 0{,}324$, $w_{\text{ORIGEN}} = 1{,}28$, $w_{\text{CAT}} = 5{,}00$, con 29 centros de los 83 candidatos disponibles. RMSE-LOOCV= 0,0170; RMSE-entrenamiento= 0,0120; R^2(entrenamiento)= 0,989. Dado que std(H2) = 0,116, el RMSE-LOOCV implica $R^2_{\text{LOOCV}} \approx 1 - (0{,}0170/0{,}116)^2 \approx 0{,}979$: el modelo explica cerca del 98 % de la varianza de H2 en validación cruzada *leave-one-out*, sensiblemente mejor que el 92.5 % del diagnóstico lineal preliminar (Tabla 2), lo cual sugiere que el RBF está capturando estructura genuinamente no lineal.

La Figura 1 muestra los diagnósticos usuales: convergencia suave del greedy (deteniéndose en 29 centros), ajuste muy cercano a la diagonal en el panel predicho-vs-real, y residuos

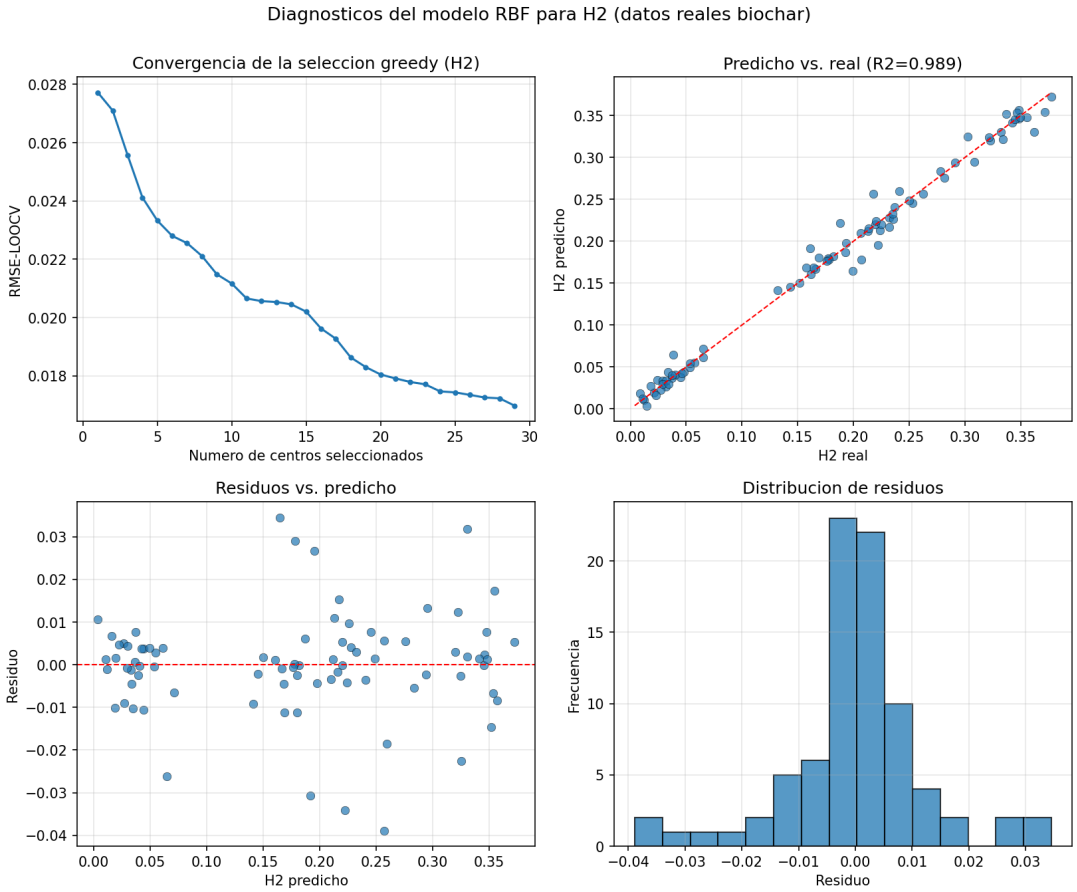


Figura 1: Diagnósticos del modelo final para H2: convergencia del RMSE-LOOCV durante la selección greedy (arriba-izq.), predicho vs. observado (arriba-der.), residuos vs. predicho (abajo-izq.) y distribución de residuos (abajo-der.).

sin un patrón sistemático fuerte (posiblemente una leve heterocedasticidad, con algo más de dispersión en el rango medio de predicción).

5.4. Dependencia parcial e interpretación fisicoquímica

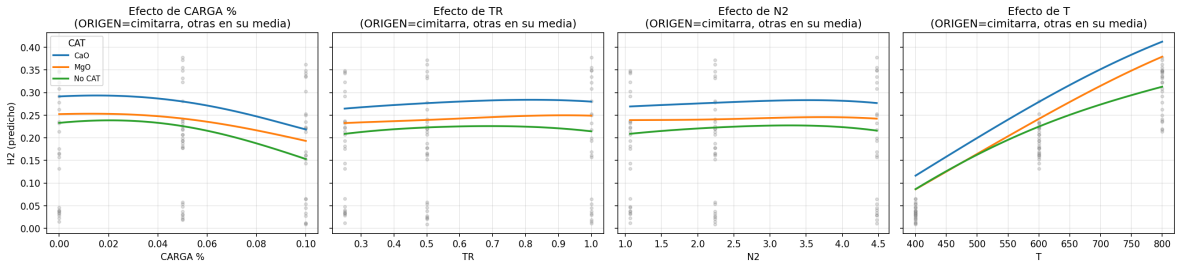


Figura 2: Efecto de cada variable continua sobre H2 predicho, estratificado por tipo de catalizador (ORIGEN fijo en la categoría más frecuente, demás variables continuas en su media muestral).

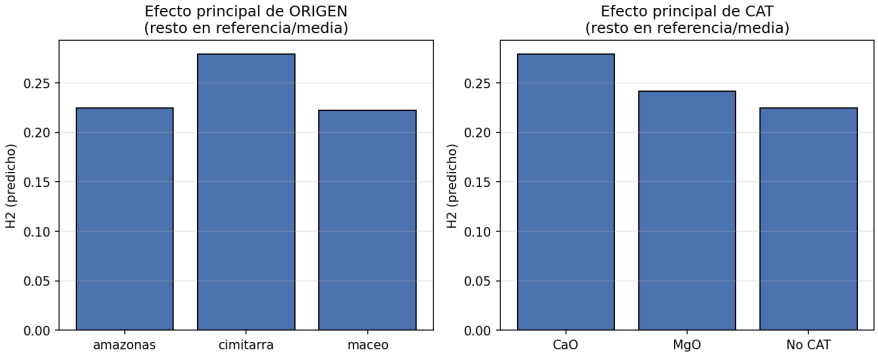


Figura 3: Efecto principal de ORIGEN y CAT sobre H2 predicho (resto de variables en su valor de referencia/media).

Dado que w_{CAT} domina consistentemente sobre w_{ORIGEN} en todas las corridas de la Tabla 3, las curvas de dependencia parcial de las variables continuas se estratificaron por CAT (Figura 2). Los resultados son físicoquímicamente coherentes:

- **La temperatura (T) domina el comportamiento**: H2 predicho sube de ∼0.10 a 400 °C hasta ∼0.35–0.42 a 800 °C, con diferencia el efecto más fuerte de las seis entradas. Es consistente con el craqueo secundario y las reacciones de reformado que se intensifican a mayor temperatura de pirólisis.
- **CaO > MgO > No CAT**, de forma consistente en todo el rango de T. Coincide con la química esperada: el CaO es conocido por promover reacciones de *water-gas-shift* y reformado intensificado por sorción (captura de CO2 como $CaCO_3$, desplazando el equilibrio hacia más H2), un mecanismo bien documentado en pirólisis catalítica de biomasa.
- CARGA %, TR y N2 muestran efectos mucho más discretos que T.
- El efecto principal de ORIGEN resultó de magnitud comparable al de CAT en el gráfico de barras (Figura 3, rango ∼0.22–0.28 para ambas variables) –pese a que los pesos

w_{ORIGEN} y w_{CAT} tomaron valores bastante distintos entre corridas (Tabla 3). Esto refuerza que los pesos categóricos individuales no son muy identificables con $N = 83$ (superficie plana en esa dirección del espacio de hiperparámetros), pero las *predicciones* del modelo final son consistentes.

Que el modelo recupere, sin haber sido guiado explícitamente hacia ello, un ordenamiento CaO > MgO > No CAT consistente con la literatura de pirólisis catalítica es la mejor validación cualitativa disponible en esta etapa: sugiere que el RBF está aprendiendo estructura física real, no ruido.

6. Discusión: sensibilidad de hiperparámetros vs. estabilidad del LOOCV

6.1. La observación empírica

La Tabla 3 documenta un patrón que merece discusión explícita: entre las corridas 2, 3 y 4, los hiperparámetros individuales –particularmente c (varía por un factor $\sim$2) y w_{ORIGEN} (varía por un factor > 4)– cambian de forma sustancial según la semilla y el presupuesto de búsqueda usados, mientras que el RMSE-LOOCV resultante permanece prácticamente constante (dentro de un 0.6 % de variación). Esto sugiere que la superficie de RMSE-LOOCV en función de $(c, \lambda, w_{\text{ORIGEN}}, w_{\text{CAT}})$ es, en una región amplia del espacio de búsqueda, relativamente **plana**: muchas combinaciones distintas de hiperparámetros producen un desempeño predictivo casi idéntico.

6.2. Conexión con la literatura de colocación RBF para EDPs

Esta observación resuena con una discusión de larga data en la literatura de métodos RBF de colocación para ecuaciones diferenciales parciales (EDPs) –un uso de las funciones de base radial metodológicamente distinto al de este trabajo (colocación/interpolación de una EDP, en lugar de aproximación regularizada de datos ruidosos), pero que comparte el mismo núcleo matemático y, por tanto, los mismos hiperparámetros de forma. Kansa (1990) [4, 5] introdujo el uso de la multicuádrica para resolver EDPs por colocación directa (el llamado *método de Kansa*), notando desde entonces que el parámetro de forma c afecta fuertemente tanto la precisión como el número de condición del sistema lineal resultante.

Schaback (1995) [7] formalizó esta tensión como un *"principio de incertidumbre"*: en el método directo de resolución del sistema RBF (RBF-Direct), no es posible mejorar la precisión (típicamente lograda con parámetros de forma más chicos, es decir, núcleos más "planos") sin empeorar simultáneamente el número de condición de la matriz de interpolación. Sin embargo, trabajos posteriores (Fornberg y Wright, y Wright y Fornberg, 2017 [8]) mostraron que este mal condicionamiento es un **artefacto del algoritmo de resolución directo**, no una limitación fundamental de la interpolación RBF en sí: métodos alternativos y numéricamente estables (RBF-QR, Contour-Padé, RBF-GA) permiten evaluar el interpolante para *cualquier* valor del parámetro de forma, incluido el límite "plano" ($c \to \infty$ en la parametrización de este informe), sin la explosión del número de condición que sufre el método directo. Kansa y Carlson (1992) [6] exploraron además el uso de parámetros de forma **variables** (distintos por centro), en lugar de un único valor global, encontrando mejoras de precisión adicionales.

6.3. El comentario del usuario: experiencia previa en colocación RBF para EDPs

El usuario aportó, a partir de su propia experiencia previa aplicando colocación RBF a la solución de EDPs, una observación directamente relevante: en ese contexto (interpola-

ción/colocación, no aproximación de datos ruidosos), la literatura muestra que los hiperparámetros del núcleo (c, y por extensión otros parámetros de escala) no son especialmente determinantes para la precisión final de la solución, siempre que se manejen dentro de rangos razonablemente amplios; la precisión de la solución está gobernada, principalmente, por el **número de centros (nodos)** usados para discretizar el dominio.

Esta observación es coherente con un resultado bien establecido en la teoría de aproximación de funciones mediante RBF: la convergencia del interpolante, a medida que aumenta la densidad de centros (equivalentemente, a medida que la distancia de llenado o *fill distance* $h \to 0$), está gobernada principalmente por la suavidad del núcleo y por h, mientras que el parámetro de forma afecta la **constante** y el **régimen numérico** (condicionamiento) de esa convergencia, pero no su existencia [9, 10]. En otras palabras: dado un número suficiente de nodos bien distribuidos, existe típicamente un rango amplio de valores de c que producen una precisión comparable y cercana al óptimo; el verdadero cuello de botella para la precisión es cuántos nodos se usan y cómo están distribuidos, no el valor preciso de c dentro de ese rango razonable.

6.4. Síntesis y diferencias importantes a señalar

La observación empírica de la Sección 6 (variación sustancial de hiperparámetros con RMSE-LOOCV casi constante) es, en espíritu, consistente con esta literatura: en ambos casos, una vez que el núcleo opera en un régimen numéricamente razonable, el resultado final es relativamente insensible al valor preciso de los hiperparámetros de forma, y lo que realmente gobierna la calidad del resultado es la asignación de centros/nodos.

Conviene, sin embargo, señalar dos diferencias metodológicas que limitan la extensión directa de esta analogía:

1. **Interpolación/colocación vs. aproximación regularizada de datos ruidosos.** En colocación de EDPs, N (el número de nodos) es una elección de diseño del usuario, libremente incrementable como parte de un refinamiento de malla, y la convergencia se estudia explícitamente como función de $N \to \infty$. En este trabajo, $N = 83$ es fijo (proviene de un ensayo experimental, no se puede "agregar más nodos" a voluntad), y el número de centros efectivamente usados por el modelo no es una elección libre del usuario sino el resultado del criterio de parada temprana del Algoritmo greedy guiado por LOOCV (Sección 2.8 del informe metodológico previo). La "regulación por número de centros" que menciona la literatura de EDPs ocurre aquí de forma **automática** vía ese criterio, no como un parámetro de refinamiento que se ajuste directamente.

2. **Ruido.** La colocación de EDPs típicamente opera sobre datos exactos (la propia EDP y sus condiciones de frontera); aquí los datos son observaciones experimentales ruidosas, y la regularización λ juega un rol adicional (controlar sobreajuste al ruido) que no tiene un análogo directo en colocación pura.

A pesar de estas diferencias, la convergencia cualitativa de ambas líneas de evidencia –la de este trabajo y la de la literatura de EDPs citada por el usuario– resulta útil como una segunda validación, independiente del diagnóstico fisicoquímico de la Sección 5, de que el comportamiento observado (baja sensibilidad de los hiperparámetros de forma, en un régimen numéricamente razonable) no es un artefacto específico de este dataset, sino una propiedad más general de los métodos RBF.

7. Limitaciones y próximos pasos

- El diagnóstico de qué gas derivar (Sección 3.2) usó un modelo lineal; conviene revisarlo una vez ajustados los 3 modelos RBF de gases, comparando el error real de CO derivado vs. CO modelado directamente.
- Falta replicar el procedimiento completo (búsqueda de rangos + ajuste final + diagnósticos) para CH4, CO2, CENIZA y % Sólido, usando la configuración de la Sección 5 como plantilla.
- La posible correlación moderada entre TR y N2 ($r = 0{,}81$, reportada en el informe metodológico previo) no se ha investigado en profundidad en el contexto del dataset real; conviene revisarla al completar los 5 modelos.
- Como se discutió en la Sección 6, los pesos categóricos individuales no parecen bien identificados con $N = 83$; no se recomienda interpretarlos como una medida precisa de "importancia relativa" de ORIGEN vs. CAT, más allá de la conclusión cualitativa de que ambos importan de forma no despreciable.

8. Conclusiones

Se aplicó exitosamente el modelo RBF multicuádrico con selección greedy y búsqueda de hiperparámetros por LHS a un dataset experimental real de pirólisis catalítica de biochar, tras un proceso de depuración que reveló correcciones sustanciales al planteamiento inicial del problema (una variable de entrada no documentada, una colinealidad perfecta, y –lo más importante– la identificación de tres columnas que en realidad son salidas del proceso, no entradas). Se extendió el modelo para incorporar variables categóricas mediante una distancia compuesta análoga al coeficiente de similitud de Gower (1971), con pesos categóricos ajustados como hiperparámetros adicionales vía LHS.

El modelo resultante para H2 alcanza un RMSE-LOOCV de 0.0170 ($R^2_{\text{LOOCV}} \approx 0{,}98$), y –sin haber sido guiado explícitamente hacia ello– recupera un ordenamiento de efecto catalítico (CaO > MgO > No CAT) consistente con la química de pirólisis catalítica conocida, además de un fuerte efecto de la temperatura consistente con el craqueo secundario esperado. La notable estabilidad del RMSE-LOOCV frente a variaciones sustanciales en los hiperparámetros individuales, observada empíricamente en este trabajo, resuena con hallazgos análogos –aunque en un contexto metodológico distinto– en la literatura de colocación RBF para ecuaciones diferenciales parciales, donde se ha documentado que, dentro de un régimen numéricamente razonable, la precisión final está gobernada principalmente por el número y distribución de los centros, no por el valor preciso de los parámetros de forma.

Referencias

[1] Gower, J. C. (1971). *A general coefficient of similarity and some of its properties*. Biometrics, 27(4), 857–871.

[2] Gower, J. C., & Legendre, P. (1986). *Metric and Euclidean properties of dissimilarity coefficients*. Journal of Classification, 3(1), 5–48.

[3] Bergstra, J., & Bengio, Y. (2012). *Random search for hyper-parameter optimization*. Journal of Machine Learning Research, 13, 281–305.

[4] Kansa, E. J. (1990). *Multiquadrics—A scattered data approximation scheme with applications to computational fluid dynamics—I: surface approximations and partial derivative estimates.* Computers & Mathematics with Applications, 19(8–9), 127–145.

[5] Kansa, E. J. (1990). *Multiquadrics—A scattered data approximation scheme with applications to computational fluid dynamics—II: solutions to parabolic, hyperbolic and elliptic partial differential equations.* Computers & Mathematics with Applications, 19(8–9), 147–161.

[6] Kansa, E. J., & Carlson, R. E. (1992). *Improved accuracy of multiquadric interpolation using variable shape parameters.* Computers & Mathematics with Applications, 24(12), 99–120.

[7] Schaback, R. (1995). *Error estimates and condition numbers for radial basis function interpolation.* Advances in Computational Mathematics, 3(3), 251–264.

[8] Wright, G. B., & Fornberg, B. (2017). *Stable computations with flat radial basis functions using vector-valued rational approximations.* Journal of Computational Physics, 331, 137–156.

[9] Wendland, H. (2005). *Scattered Data Approximation.* Cambridge University Press.

[10] Fasshauer, G. E. (2007). *Meshfree Approximation Methods with MATLAB.* World Scientific.