Aproximación de datos experimentales dispersos mediante redes de funciones de base radial (RBF) multicuádricas: marco teórico, algoritmo y validación

Reporte técnico

13 de agosto de 2026

Resumen

Se presenta el diseño de un modelo de aproximación basado en funciones de base radial (RBF, *Radial Basis Functions*) con núcleo multicuádrico, orientado a un problema de regresión con $N = 84$ observaciones experimentales, $d = 5$ variables independientes y una variable dependiente, en presencia de ruido de medición no despreciable. Dado el carácter disperso de los datos (pocos puntos en un espacio de dimensión relativamente alta) y su naturaleza ruidosa, el modelo combina cuatro ingredientes: (i) estandarización de las variables independientes, (ii) regularización de Tikhonov (*ridge*) sobre los pesos radiales, (iii) selección *greedy* de centros guiada por un estimador analítico del error de validación cruzada *leave-one-out* (LOOCV), calculado mediante la fórmula de Rippa/Allen sin necesidad de reajustar el modelo N veces, y (iv) búsqueda en grilla de los hiperparámetros (parámetro de forma c y coeficiente de regularización λ). Se documenta el marco teórico completo, la derivación de la fórmula de LOOCV eficiente, el algoritmo propuesto y su validación numérica sobre datos sintéticos con estructura y nivel de ruido comparable al problema real.

Índice

1. Introducción y planteamiento del problema **2**

2. Marco teórico **3**

2.1. Funciones de base radial (RBF) . . . 3
2.2. Funciones condicionalmente definidas positivas y el término polinomial . . . 3
2.3. Estandarización de las variables independientes . . . 4
2.4. Regularización de Tikhonov (regresión *ridge*) . . . 4
2.5. Sobreajuste y el *trade-off* sesgo–varianza . . . 4
2.6. Validación cruzada *leave-one-out* (LOOCV) . . . 5
2.7. Cálculo analítico de LOOCV: fórmula de Rippa / Allen (PRESS) . . . 5
2.7.1. Resultado y notación . . . 5
2.7.2. Derivación . . . 6
2.7.3. Cálculo numéricamente estable de h_{ii} . . . 6
2.8. Selección *greedy* de centros . . . 7
2.8.1. Motivación . . . 7
2.8.2. Antecedente: mínimos cuadrados ortogonales (OLS) . . . 7
2.8.3. Criterio adoptado en este trabajo . . . 7
2.9. Búsqueda de hiperparámetros . . . 8

3. Metodología propuesta: algoritmo completo **9**

4. Resultados experimentales **9**
4.1. Convergencia de la selección greedy y calidad del ajuste 10
4.2. Curvas de dependencia parcial 10
4.3. Error de entrenamiento vs. error LOOCV: evidencia empírica del sobreajuste . 11
4.4. Validación numérica de la fórmula de Rippa/Allen 11
4.5. Eficiencia numérica: Cholesky vs. inversión explícita 12

5. Estructura de dos niveles del objetivo y estrategia de muestreo de hiperparámetros **12**
5.1. Dos niveles de función objetivo 13
5.2. Grid search vs. muestreo aleatorio y quasi-aleatorio 13
5.2.1. El argumento de Bergstra & Bengio (2012) 14
5.2.2. Latin Hypercube Sampling 14
5.3. Comparación empírica sobre el problema propuesto 14
5.4. Elección final y extensiones futuras 15

6. Limitaciones y recomendaciones **16**

7. Conclusiones **16**

1. Introducción y planteamiento del problema

Se dispone de un conjunto de $N = 84$ observaciones experimentales de la forma

$$\left(x_1^{(i)}, x_2^{(i)}, x_3^{(i)}, x_4^{(i)}, x_5^{(i)}, z^{(i)}\right), \qquad i = 1, \ldots, N,$$

que se interpreta como muestras ruidosas de una función subyacente desconocida

$$z = f(x_1, x_2, x_3, x_4, x_5) + \varepsilon,$$

donde ε representa el error experimental (ruido de medición). El objetivo es construir un modelo $\hat{f} : \mathbb{R}^5 \to \mathbb{R}$ que aproxime f a partir de estas observaciones, siendo utilizable tanto para interpolación dentro del dominio muestreado como, con las debidas reservas, para predicción en puntos cercanos no observados.

El problema presenta dos dificultades que condicionan cada decisión de diseño del modelo:

(a) **Dispersión de los datos (*sparsity*).** Con $N = 84$ puntos en un espacio de $d = 5$ dimensiones, la densidad efectiva de muestreo por dimensión es baja. Este es el efecto conocido como *maldición de la dimensionalidad* (*curse of dimensionality*): el volumen del espacio de entrada crece exponencialmente con d, mientras que el número de datos permanece fijo, de modo que las regiones del dominio quedan, en promedio, pobremente muestreadas.

(b) **Ruido experimental.** Al tratarse de datos de ensayo, cada observación $z^{(i)}$ contiene un componente de error no despreciable. Esto descarta, de entrada, cualquier esquema de **interpolación exacta** (que fuerza $\hat{f}(x^{(i)}) = z^{(i)}$ para todo i): un interpolante exacto reproduciría el ruido junto con la señal, produciendo un modelo con mínima varianza aparente en entrenamiento pero pésima capacidad de generalización.

Estas dos condiciones motivan el uso de una red RBF regularizada, con selección de centros guiada explícitamente por una estimación de error de generalización (no de error de entrenamiento), como se detalla en las secciones siguientes.

2. Marco teórico

2.1. Funciones de base radial (RBF)

Una función de base radial es una función $\phi : \mathbb{R}_{\geq 0} \to \mathbb{R}$ que depende únicamente de la distancia (norma euclídea) entre un punto de evaluación $\mathbf{x} \in \mathbb{R}^d$ y un *centro* $\mathbf{c}_j \in \mathbb{R}^d$:

$$\phi_j(\mathbf{x}) = \phi(\|\mathbf{x} - \mathbf{c}_j\|) = \phi(r), \qquad r = \|\mathbf{x} - \mathbf{c}_j\|.$$

Un modelo RBF aproxima la función objetivo como una combinación lineal de estas funciones centradas en un conjunto de puntos $\{\mathbf{c}_1, \ldots, \mathbf{c}_M\}$:

$$\hat{f}(\mathbf{x}) = \sum_{j=1}^{M} w_j \, \phi(\|\mathbf{x} - \mathbf{c}_j\|) + p(\mathbf{x}),$$

donde $p(\mathbf{x})$ es, opcionalmente, un polinomio de bajo grado (típicamente constante o lineal) cuyo rol se explica en la sección 2.2.

La elección del núcleo ϕ determina las propiedades de aproximación del modelo. En este trabajo se emplea el núcleo **multicuádrico**:

$$\boxed{\phi(r) = \sqrt{r^2 + c^2}}$$

donde $c > 0$ es el *parámetro de forma* (*shape parameter*). A diferencia de núcleos como el gaussiano $\phi(r) = e^{-r^2/c^2}$, la multicuádrica es una función **no acotada y monótona creciente** en r: no decae a cero lejos del centro, lo que le confiere mejor comportamiento numérico (matrices menos mal condicionadas en muchos regímenes) y una capacidad de aproximación global reconocida empíricamente como muy buena incluso con relativamente pocos centros [7, 8, 9].

2.2. Funciones condicionalmente definidas positivas y el término polinomial

La multicuádrica **no** es una función definida positiva en el sentido clásico (Bochner), sino **condicionalmente definida positiva de orden 1** [6]. Esto significa que la matriz $\mathbf{\Phi}$ con entradas $\mathbf{\Phi}_{ij} = \phi(\|\mathbf{c}_i - \mathbf{c}_j\|)$ no es, en general, definida positiva sobre todo $\mathbb{R}^M$, sino únicamente sobre el subespacio de vectores $\mathbf{v}$ que satisfacen la restricción lineal $\sum_i v_i = 0$.

La consecuencia práctica clásica (en el problema de interpolación exacta, sin regularización) es que, para garantizar que el sistema lineal sea resoluble de forma única, es necesario añadir un término polinomial $p(\mathbf{x})$ de grado acorde al orden de condicionalidad (una constante, para orden 1) y una restricción de ortogonalidad de la forma $\sum_j w_j \, q(\mathbf{c}_j) = 0$ para todo polinomio q de ese grado [6, 7].

En el presente trabajo, dado que el ajuste es **regularizado** (no es interpolación exacta), se opta por una relajación práctica y ampliamente usada en la literatura de redes RBF [2]: se incorpora una cola polinomial de grado 1 (constante más términos lineales)

$$p(\mathbf{x}) = \beta_0 + \sum_{k=1}^{d} \beta_k x_k,$$

sin penalización de regularización sobre los coeficientes β_k, y **sin** imponer la restricción de ortogonalidad estricta. Este término cumple dos funciones: (i) captura la tendencia global lineal de los datos, aliviando a la parte radial de tener que modelarla, y (ii) mejora sustancialmente el comportamiento del modelo fuera de la envolvente convexa de los datos de entrenamiento (extrapolación), donde las RBF puras tienden a producir valores poco confiables.

2.3. Estandarización de las variables independientes

Como ϕ depende de la distancia euclídea $\|\mathbf{x} - \mathbf{c}_j\|$, la escala relativa de las variables $x_1, \ldots, x_5$ afecta directamente la forma del modelo: si una variable tiene un rango numérico mucho mayor que las demás, la distancia queda dominada por esa variable y las demás se vuelven, en la práctica, irrelevantes para el núcleo. Por ello, antes de cualquier cálculo de distancias se estandariza cada variable (transformación *z-score*):

$$\tilde{x}_k = \frac{x_k - \mu_k}{\sigma_k}, \qquad \mu_k = \frac{1}{N}\sum_{i=1}^{N} x_k^{(i)}, \qquad \sigma_k = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\left(x_k^{(i)} - \mu_k\right)^2},$$

para $k = 1, \ldots, 5$. Todas las distancias, centros y evaluaciones del modelo se realizan en este espacio estandarizado; las predicciones sobre nuevos puntos se obtienen aplicando la misma transformación (con los μ_k, σ_k estimados en el conjunto de entrenamiento).

2.4. Regularización de Tikhonov (regresión *ridge*)

Dado un conjunto fijo de M centros, la matriz de diseño $\mathbf{\Phi} \in \mathbb{R}^{N\times(M+d+1)}$ se construye evaluando el núcleo (y la cola polinomial) en cada punto de entrenamiento:

$$\mathbf{\Phi}_{i,\cdot} = \Big[1,\ \tilde{x}_1^{(i)}, \ldots, \tilde{x}_5^{(i)},\ \phi\big(\|\tilde{\mathbf{x}}^{(i)} - \mathbf{c}_1\|\big), \ldots, \phi\big(\|\tilde{\mathbf{x}}^{(i)} - \mathbf{c}_M\|\big)\Big].$$

El ajuste por mínimos cuadrados ordinarios, $\mathbf{w} = \arg\min_{\mathbf{w}} \|\mathbf{\Phi}\mathbf{w} - \mathbf{y}\|^2$, interpola exactamente cuando $M = N$ y es propenso al sobreajuste incluso para $M < N$ si los centros están muy próximos entre sí (columnas de $\mathbf{\Phi}$ casi colineales). Para estabilizar el ajuste y penalizar soluciones con pesos radiales grandes (típicamente asociadas a oscilaciones espúreas ajustadas al ruido), se emplea regularización de Tikhonov [4, 5]:

$$\mathbf{w} = \arg\min_{\mathbf{w}} \ \|\mathbf{\Phi}\mathbf{w} - \mathbf{y}\|^2 \ + \ \lambda \sum_{j\,\in\,\text{radiales}} w_j^2, \qquad \lambda \geq 0,$$

donde la suma de penalización corre **solo** sobre los pesos asociados a las funciones radiales, dejando sin penalizar los coeficientes β_k de la cola polinomial (consistente con la práctica estándar de no penalizar términos de tendencia determinística). Definiendo la matriz diagonal de penalización

$$P = \operatorname{diag}(\underbrace{0, \ldots, 0}_{d+1}, \underbrace{\lambda, \ldots, \lambda}_{M}),$$

la solución en forma cerrada es

$$\mathbf{w} = \big(\mathbf{\Phi}^\top\mathbf{\Phi} + P\big)^{-1}\mathbf{\Phi}^\top\mathbf{y} \ \equiv \ A^{-1}\mathbf{\Phi}^\top\mathbf{y}, \qquad A := \mathbf{\Phi}^\top\mathbf{\Phi} + P.$$

El parámetro λ controla el equilibrio sesgo–varianza: $\lambda \to 0$ recupera mínimos cuadrados sin restricciones (bajo sesgo, alta varianza); $\lambda \to \infty$ fuerza $\mathbf{w} \to \mathbf{0}$ (alto sesgo, baja varianza). El valor óptimo se determina empíricamente mediante validación cruzada (sección 2.6).

2.5. Sobreajuste y el *trade-off* sesgo–varianza

El **error de entrenamiento**, $\mathrm{RMSE}_{\text{train}} = \sqrt{\frac{1}{N}\sum_i (z^{(i)} - \hat{f}(\mathbf{x}^{(i)}))^2}$, mide qué tan bien el modelo reproduce los mismos datos usados para ajustarlo. Este error es una función **monótona no creciente** de la complejidad del modelo (número de centros M, o $1/\lambda$): agregar más centros, o reducir λ, nunca puede empeorar el ajuste a los datos observados, y en el límite de interpolación exacta ($M = N$, $\lambda = 0$) el error de entrenamiento es idénticamente cero.

Sin embargo, un error de entrenamiento nulo no implica un buen modelo: si el modelo tiene suficiente flexibilidad para pasar exactamente por cada punto observado, también pasará exactamente por el *ruido* de cada punto, produciendo oscilaciones espúreas entre observaciones que no reflejan la función subyacente f. Este fenómeno, el **sobreajuste** (*overfitting*), es especialmente severo en el problema aquí tratado por la combinación de pocos datos, alta dimensionalidad y ruido no despreciable.

La cantidad relevante para elegir la complejidad del modelo es el **error de generalización**: el error esperado sobre datos *no vistos* durante el ajuste. Como no se dispone de un conjunto de prueba independiente adicional (dado que $N = 84$ es ya reducido), este error se estima mediante validación cruzada.

2.6. Validación cruzada *leave-one-out* (LOOCV)

La validación cruzada *leave-one-out* consiste en, para cada observación $i = 1, \ldots, N$: (1) ajustar el modelo usando las $N-1$ observaciones restantes; (2) predecir en el punto i excluido, $\hat{f}_{(-i)}(\mathbf{x}^{(i)})$; (3) registrar el residuo $e_i^{\mathrm{LOO}} = z^{(i)} - \hat{f}_{(-i)}(\mathbf{x}^{(i)})$. El error de validación cruzada se resume como

$$\mathrm{RMSE}_{\mathrm{LOOCV}} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\left(e_i^{\mathrm{LOO}}\right)^2}.$$

Como cada predicción $\hat{f}_{(-i)}(\mathbf{x}^{(i)})$ se genera con un modelo que **nunca vio** la observación i, $\mathrm{RMSE}_{\mathrm{LOOCV}}$ es un estimador (aproximadamente) insesgado del error de generalización, y –a diferencia del error de entrenamiento– **no** es monótono en la complejidad del modelo: típicamente decrece al agregar los primeros centros (el modelo captura estructura real de f) y luego crece de nuevo cuando el modelo comienza a memorizar el ruido de la muestra específica. El mínimo de esta curva en forma de "U" identifica la complejidad de modelo que mejor equilibra sesgo y varianza dados los datos disponibles.

Implementado de forma directa (*fuerza bruta*), LOOCV exige N ajustes completos del modelo por cada configuración de hiperparámetros (c, λ, M) evaluada. Dado que el algoritmo aquí propuesto evalúa un número muy grande de configuraciones (búsqueda en grilla de c y λ, combinada con selección greedy de hasta M centros, probando en cada paso todos los candidatos restantes), el cósto de fuerza bruta resulta prohibitivo. La sección siguiente presenta el resultado clásico que permite calcular $\mathrm{RMSE}_{\mathrm{LOOCV}}$ de forma **exacta** con un único ajuste sobre todos los datos.

2.7. Cálculo analítico de LOOCV: fórmula de Rippa / Allen (PRESS)

2.7.1. Resultado y notación

Sea $\hat{\mathbf{y}} = \mathbf{\Phi w} = H\mathbf{y}$ el vector de valores ajustados con **todos** los N datos, donde

$$H = \mathbf{\Phi} A^{-1} \mathbf{\Phi}^{\top}, \qquad A = \mathbf{\Phi}^{\top}\mathbf{\Phi} + P,$$

es la **matriz de influencia** (*hat matrix*). Sea $e_i = z^{(i)} - \hat{z}^{(i)}$ el residuo ordinario (con el modelo completo) y $h_{ii} = H_{ii}$ la i-ésima entrada diagonal de H (el *leverage* o "autoinfluencia" del punto i: cuánto influye $z^{(i)}$ sobre su propia predicción $\hat{z}^{(i)}$). Entonces el residuo *leave-one-out* exacto satisface

$$\boxed{e_i^{\mathrm{LOO}} = \frac{e_i}{1 - h_{ii}}} \qquad i = 1, \ldots, N.$$

Este resultado fue establecido por Allen [3] en el contexto general de regresión lineal (como el estadístico PRESS), y fue popularizado específicamente para la selección del parámetro

de forma en interpolación RBF por Rippa [1], quién lo formuló para el caso particular de interpolación **exacta** (sin regularización, $M = N$) en la forma equivalente

$$e_i^{\mathrm{LOO}} = \frac{w_i}{\left(\mathbf{\Phi}^{-1}\right)_{ii}},$$

usando directamente los pesos de interpolación w_i y la diagonal de la matriz inversa $\mathbf{\Phi}^{-1}$. Esta forma alternativa es necesaria en el caso de interpolación exacta porque allí $e_i \equiv 0$ y $h_{ii} \equiv 1$ para todo i (el modelo reproduce cada dato exactamente), de modo que la expresión general $e_i/(1 - h_{ii})$ resulta en una indeterminación $0/0$. En el presente trabajo, al emplearse regularización ($\lambda > 0$), se evita este caso degenerado y se utiliza directamente la forma general de Allen/Rippa, $e_i^{\mathrm{LOO}} = e_i/(1 - h_{ii})$.

2.7.2. Derivación

Se presenta la derivación completa por ser el resultado central que hace computacionalmente viable el algoritmo propuesto.

Sea $\phi_i^\top$ la i-ésima fila de $\mathbf{\Phi}$ (de modo que $\mathbf{\Phi}^\top\mathbf{\Phi} = \sum_{j=1}^{N} \phi_j\phi_j^\top$). Al excluir la observación i, la nueva matriz normal es una actualización de **rango 1**:

$$A_{(-i)} = A - \phi_i\phi_i^\top.$$

Por la fórmula de Sherman–Morrison [10],

$$A_{(-i)}^{-1} = A^{-1} + \frac{A^{-1}\phi_i\phi_i^\top A^{-1}}{1 - \phi_i^\top A^{-1}\phi_i} = A^{-1} + \frac{\mathbf{g}\,\mathbf{g}^\top}{1 - h_{ii}}, \qquad \mathbf{g} := A^{-1}\phi_i,$$

donde se usó que $h_{ii} = \phi_i^\top A^{-1}\phi_i$. El vector de pesos ajustado sin la observación i es

$$\mathbf{w}_{(-i)} = A_{(-i)}^{-1}\left(\mathbf{\Phi}^\top\mathbf{y} - \phi_i z^{(i)}\right).$$

Expandiendo, usando $A^{-1}\mathbf{\Phi}^\top\mathbf{y} = \mathbf{w}$ (el ajuste completo), $\mathbf{g}^\top\mathbf{\Phi}^\top\mathbf{y} = \phi_i^\top\mathbf{w} = \hat{z}^{(i)}$, y $\mathbf{g}^\top\phi_i = h_{ii}$, tras simplificar términos se obtiene

$$\mathbf{w}_{(-i)} = \mathbf{w} - \mathbf{g}\,\frac{z^{(i)} - \hat{z}^{(i)}}{1 - h_{ii}} = \mathbf{w} - \mathbf{g}\,\frac{e_i}{1 - h_{ii}}.$$

La predicción en el punto excluído, usando este nuevo vector de pesos, es

$$\hat{z}_{(-i)}^{(i)} = \phi_i^\top\mathbf{w}_{(-i)} = \hat{z}^{(i)} - h_{ii}\,\frac{e_i}{1 - h_{ii}}.$$

Finalmente, el residuo *leave-one-out* resulta

$$e_i^{\mathrm{LOO}} = z^{(i)} - \hat{z}_{(-i)}^{(i)} = e_i + h_{ii}\frac{e_i}{1 - h_{ii}} = e_i\left(\frac{1 - h_{ii} + h_{ii}}{1 - h_{ii}}\right) = \frac{e_i}{1 - h_{ii}},$$

que es el resultado enunciado. ■

2.7.3. Cálculo numéricamente estable de h_{ii}

La expresión $h_{ii} = \phi_i^\top A^{-1}\phi_i$ podría calcularse formando explícitamente A^{-1} y luego la matriz completa $H = \mathbf{\Phi}A^{-1}\mathbf{\Phi}^\top$, extrayendo después su diagonal. Sin embargo, este enfoque es innecesariamente costoso: forma una matriz $N \times N$ completa cuando solo se requieren sus N entradas diagonales, y la inversión explícita de matrices amplifica el número de condición, siendo menos estable numéricamente que resolver sistemas triangulares [10, 11].

En su lugar, se factoriza A por Cholesky ($A = LL^\top$, válida por ser A simétrica y definida positiva para $\lambda > 0$), y se observa que

$$h_{ii} = \phi_i^\top A^{-1} \phi_i = \phi_i^\top L^{-\top} L^{-1} \phi_i = \left\| L^{-1} \phi_i \right\|^2.$$

Definiendo $V^\top := L^{-1}\boldsymbol{\Phi}^\top$ (obtenido resolviendo un único sistema triangular $LV^\top = \boldsymbol{\Phi}^\top$ con los N lados derechos simultáneamente), se obtiene toda la diagonal de H como

$$h_{ii} = \sum_k V_{ki}^2,$$

es decir, la suma de cuadrados de la columna i de $V^\top$. El vector de pesos $\mathbf{w} = A^{-1}\boldsymbol{\Phi}^\top \mathbf{y}$ se obtiene, sin invertir A, con dos sustituciones triangulares adicionales ($L\mathbf{z} = \boldsymbol{\Phi}^\top \mathbf{y}$, luego $L^\top \mathbf{w} = \mathbf{z}$). Este procedimiento evita tanto la inversión explícita de A como la formación de H completa.

Se verificó empíricamente (Sección 4.4) que este cálculo coincide con LOOCV por fuerza bruta hasta precisión numérica de máquina, y que la ganancia en tiempo de cómputo frente al enfoque por inversión explícita es despreciable a la escala del problema tratado ($N = 84$) pero se vuelve sustancial (varias veces más rápido) para conjuntos de datos de miles de puntos.

2.8. Selección *greedy* de centros

2.8.1. Motivación

En principio, cada uno de los $N = 84$ puntos de entrenamiento es un candidato válido para ser centro de una función radial. Usar los N puntos como centros del modelo (interpolación/regresión completa) es una opción, pero no necesariamente la mejor: además del riesgo de sobreajuste ya discutido, un número menor de centros produce un modelo más simple, interpretable y de menor costo de evaluación, sin sacrificar precisión si los centros se eligen adecuadamente.

El problema de seleccionar el subconjunto óptimo de M centros de entre N candidatos es combinatorio ($\binom{N}{M}$ posibilidades) y por tanto intratable por búsqueda exhaustiva. La solución adoptada es una **heurística greedy** (voraz): construir el subconjunto de centros de forma incremental, agregando en cada paso el candidato que produce la mayor mejora en un criterio dado, sin reconsiderar decisiones previas.

2.8.2. Antecedente: mínimos cuadrados ortogonales (OLS)

El algoritmo greedy clásico para selección de centros en redes RBF es el método de **mínimos cuadrados ortogonales** (*Orthogonal Least Squares*, OLS) de Chen, Cowan y Grant [2]. En su formulación original, en cada iteración se ortogonaliza (vía Gram-Schmidt) la columna de cada candidato restante contra las columnas ya seleccionadas, y se elige el candidato cuya componente ortogonal explica la mayor proporción de la varianza aún no explicada del vector objetivo (el llamado *error reduction ratio*, ERR). Este esquema es elegante porque la ortogonalización incremental evita reajustar el sistema completo en cada paso.

2.8.3. Criterio adoptado en este trabajo

El criterio ERR clásico persigue minimizar el error de **entrenamiento** en cada paso, lo cual –como se discutió en la Sección 2.5– no es el objetivo correcto cuando los datos son ruidosos: perseguir la máxima reducción de error de entrenamiento en cada paso conduciría, sin un criterio de parada adecuado, a agregar todos los centros disponibles.

En este trabajo se adapta el esquema greedy reemplazando el criterio de selección: en cada iteración, para cada candidato x_k aún no seleccionado, se evalúa el $\mathrm{RMSE}_{\mathrm{LOOCV}}$ (Secciones 2.6–2.7) del modelo resultante de agregar x_k al conjunto de centros actual, y se selecciona el candidato que produce el **menor** $\mathrm{RMSE}_{\mathrm{LOOCV}}$. El proceso se detiene (criterio de parada temprana) cuando ningún candidato restante mejora el $\mathrm{RMSE}_{\mathrm{LOOCV}}$ actual en al menos una tolerancia $\delta_{\mathrm{mín}}$, evitando así que el algoritmo agregue centros que solo mejorarían el ajuste a los datos observados sin mejorar –de hecho, empeorando– la capacidad de generalización estimada.

El pseudocódigo completo se presenta en el Algoritmo 1.

Algorithm 1 Selección greedy de centros guiada por LOOCV

Require: Datos estandarizados $\{(\tilde{\mathbf{x}}^{(i)}, z^{(i)})\}_{i=1}^{N}$; parámetro de forma c; regularización λ; máximo de centros $M_{\mathrm{máx}}$; tolerancia $\delta_{\mathrm{mín}}$
Ensure: Conjunto de centros seleccionados $\mathcal{S}$

$\mathcal{S} \leftarrow \emptyset$; $\quad \mathcal{R} \leftarrow \{1, \ldots, N\}$ $\quad$ (candidatos restantes)
$\mathrm{LOOCV}_{\mathrm{mejor}} \leftarrow +\infty$
while $\mathcal{R} \neq \emptyset$ **y** $|\mathcal{S}| < M_{\mathrm{máx}}$ **do**
  for cada candidato $k \in \mathcal{R}$ **do**
    Construir $\mathbf{\Phi}$ con centros $\mathcal{S} \cup \{k\}$
    Calcular $\mathrm{RMSE}_{\mathrm{LOOCV}}(k)$ vía fórmula de Rippa/Allen (Alg. 2)
  end for
  $k^* \leftarrow \arg\mín_{k \in \mathcal{R}} \mathrm{RMSE}_{\mathrm{LOOCV}}(k)$
  if $|\mathcal{S}| > 0$ **y** $\mathrm{LOOCV}_{\mathrm{mejor}} - \mathrm{RMSE}_{\mathrm{LOOCV}}(k^*) < \delta_{\mathrm{mín}}$ **then**
    romper (detención temprana: no hay mejora significativa)
  end if
  $\mathcal{S} \leftarrow \mathcal{S} \cup \{k^*\}$; $\quad \mathcal{R} \leftarrow \mathcal{R} \setminus \{k^*\}$
  $\mathrm{LOOCV}_{\mathrm{mejor}} \leftarrow \mathrm{RMSE}_{\mathrm{LOOCV}}(k^*)$
end while
return $\mathcal{S}$

Algorithm 2 Cálculo de $\mathrm{RMSE}_{\mathrm{LOOCV}}$ (fórmula de Rippa/Allen)

Require: Matriz de diseño $\mathbf{\Phi}$; objetivo $\mathbf{y}$; regularización λ; índice n_u de columnas no penalizadas
Ensure: $\mathbf{w}$, $\mathrm{RMSE}_{\mathrm{train}}$, $\mathrm{RMSE}_{\mathrm{LOOCV}}$

$P \leftarrow \mathrm{diag}(0, \ldots, 0, \lambda, \ldots, \lambda)$ ▷ ceros en las primeras n_u entradas
$A \leftarrow \mathbf{\Phi}^\top \mathbf{\Phi} + P$
$L \leftarrow \mathrm{Cholesky}(A)$ ▷ $A = LL^\top$
Resolver $L\mathbf{z} = \mathbf{\Phi}^\top \mathbf{y}$, luego $L^\top \mathbf{w} = \mathbf{z}$ ▷ sin invertir A
Resolver $LV^\top = \mathbf{\Phi}^\top$ ▷ N lados derechos simultáneos
$h_{ii} \leftarrow \sum_k V_{ki}^2$ para $i = 1, \ldots, N$
$\mathbf{e} \leftarrow \mathbf{y} - \mathbf{\Phi}\mathbf{w}$
$\mathbf{e}^{\mathrm{LOO}} \leftarrow \mathbf{e} \,/\, (1 - \mathbf{h})$ ▷ división elemento a elemento
return $\mathbf{w}$, $\|\mathbf{e}\|/\sqrt{N}$, $\|\mathbf{e}^{\mathrm{LOO}}\|/\sqrt{N}$

2.9. Búsqueda de hiperparámetros

El modelo depende de dos hiperparámetros continuos: el parámetro de forma c de la multicuádrica y el coeficiente de regularización λ. Ambos se seleccionan mediante **búsqueda en**

grilla (*grid search*) sobre rangos log-espaciados,

$$c \in \{c_1, \ldots, c_{n_c}\} \subset [c_{\text{mín}}, c_{\text{máx}}], \qquad \lambda \in \{\lambda_1, \ldots, \lambda_{n_\lambda}\} \subset [\lambda_{\text{mín}}, \lambda_{\text{máx}}],$$

ejecutando, para cada combinación (c, λ), el procedimiento greedy completo (Algoritmo 1) y registrando el $\text{RMSE}_{\text{LOOCV}}$ final alcanzado. Se retiene la combinación (c^*, λ^*) y el conjunto de centros $\mathcal{S}^*$ que produce el menor $\text{RMSE}_{\text{LOOCV}}$ global. Gracias a que cada evaluación individual usa la fórmula analítica de Rippa/Allen (en vez de LOOCV por fuerza bruta), esta búsqueda –que involucra típicamente cientos de miles de evaluaciones de modelo– resulta computacionalmente factible en un tiempo del orden de un minuto para $N = 84$.

3. Metodología propuesta: algoritmo completo

Integrando los elementos de la sección anterior, el procedimiento completo de ajuste es el siguiente:

1. **Preprocesamiento.** Estandarizar las cinco variables independientes (z-score) usando media y desviación estándar calculadas sobre el conjunto de entrenamiento.
2. **Muestreo de hiperparámetros.** Para cada par (c, λ) muestreado[1]:
   a) Ejecutar la selección greedy de centros (Algoritmo 1), guiada por $\text{RMSE}_{\text{LOOCV}}$ calculado vía la fórmula de Rippa/Allen (Algoritmo 2).
   b) Registrar el $\text{RMSE}_{\text{LOOCV}}$ final y el conjunto de centros resultante.
3. **Selección del modelo final.** Elegir $(c^*, \lambda^*, \mathcal{S}^*)$ como la combinación de menor $\text{RMSE}_{\text{LOOCV}}$ entre todas las evaluadas.
4. **Ajuste final.** Con los centros $\mathcal{S}^*$ (en el espacio estandarizado) y los hiperparámetros óptimos, resolver
   $$\mathbf{w}^* = \left(\boldsymbol{\Phi}^\top \boldsymbol{\Phi} + P^*\right)^{-1} \boldsymbol{\Phi}^\top \mathbf{y}$$
   (vía Cholesky, Sección 2.7.3) sobre **todos** los $N = 84$ datos.
5. **Predicción.** Para un punto nuevo $\mathbf{x}_{\text{new}}$: estandarizar con los μ_k, σ_k del entrenamiento, construir la fila de diseño correspondiente y evaluar $\hat{z} = \boldsymbol{\Phi}_{\text{new}} \mathbf{w}^*$.

Este procedimiento queda encapsulado, en la implementación de referencia, en la clase `RBFApproximator` (métodos `fit` y `predict`), sobre el módulo `rbf_multiquadric.py`.

4. Resultados experimentales

Con el fin de validar el comportamiento del algoritmo sin depender aún de los datos experimentales reales del ensayo, se generó un conjunto sintético con la misma estructura del problema real: $N = 84$ observaciones, $d = 5$ variables independientes muestreadas uniformemente en $[-2, 2]^5$, una función subyacente no lineal con interacciones entre variables,

$$f(\mathbf{x}) = \sin(x_1) + 0{,}5\, x_2^2 - x_3 x_4 + 0{,}3\, x_5 + 0{,}2 \cos(x_1 x_5),$$

y ruido aditivo Gaussiano de desviación estándar igual al 15 % de la desviación estándar de f sobre la muestra, $\varepsilon \sim \mathcal{N}(0,\ (0{,}15\, \sigma_f)^2)$.

[1] En el diseño original de este trabajo, este paso se implementó como una búsqueda en grilla regular. La Sección 5 compara esa estrategia con alternativas de muestreo aleatorio y quasi-aleatorio (Latin Hypercube Sampling), y justifica la adopción de esta última como configuración por defecto en la implementación de referencia.

4.1. Convergencia de la selección greedy y calidad del ajuste

La Figura 1 resume el comportamiento del modelo ajustado mediante el procedimiento completo (búsqueda en grilla + greedy + ajuste final). El panel superior izquierdo muestra la curva de convergencia del $\mathrm{RMSE}_{\mathrm{LOOCV}}$ durante la selección greedy: decrece con las primeras incorporaciones de centros y se estabiliza (activando el criterio de parada temprana) alrededor de $M = 28$ centros de los 84 candidatos disponibles. Los paneles restantes muestran, respectivamente, el ajuste predicho contra el valor real ($R^2 \approx 0{,}988$ sobre el conjunto de entrenamiento completo), los residuos en función del valor predicho (sin patrones sistemáticos evidentes) y la distribución de dichos residuos.

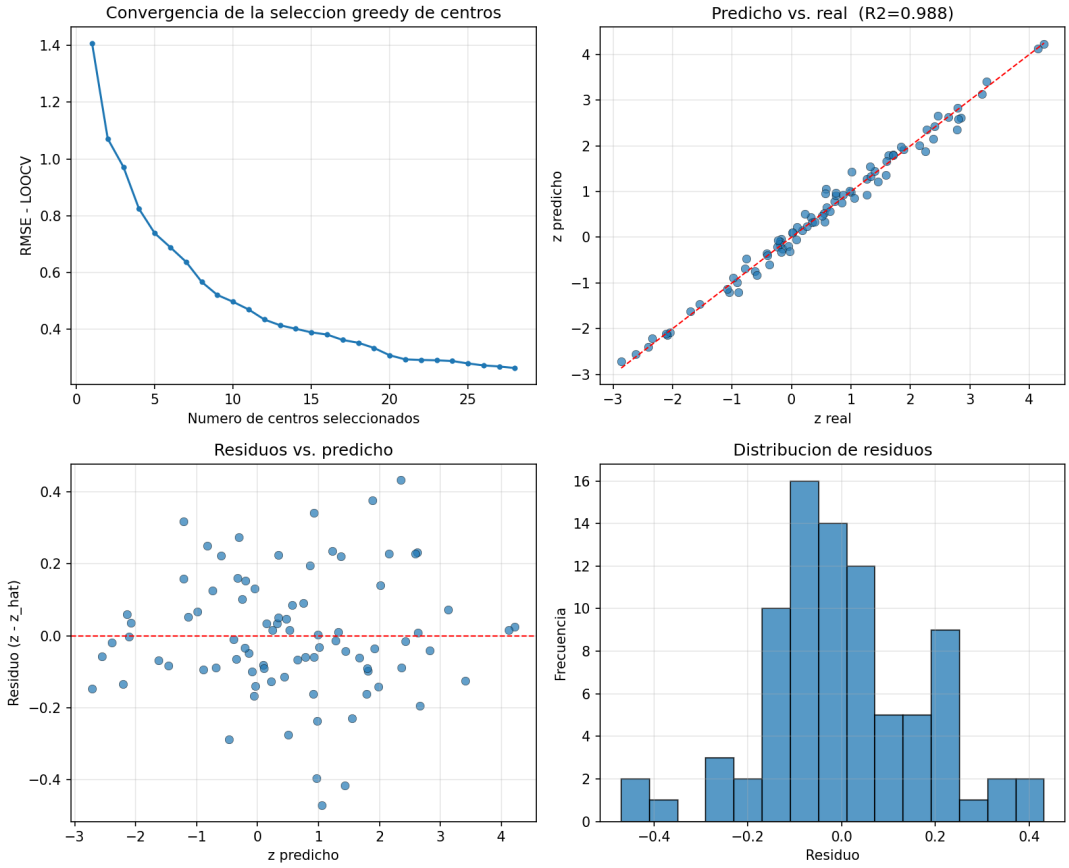


Figura 1: Diagnósticos del modelo ajustado sobre el conjunto sintético de validación: convergencia del LOOCV durante la selección greedy (arriba-izq.), valores predichos vs. observados (arriba-der.), residuos vs. predicho (abajo-izq.) y distribución de residuos (abajo-der.).

4.2. Curvas de dependencia parcial

Para explorar el efecto marginal de cada variable independiente, la Figura 2 presenta, para cada x_k, la predicción del modelo al variar x_k en su rango observado mientras las demás variables se fijan en su valor medio. Estas curvas son un corte unidimensional de una superficie de respuesta de cinco dimensiones y, por construcción, no capturan efectos de **interacción** entre variables (por ejemplo, el término $-x_3x_4$ de la función generadora no se manifiesta claramente en los paneles individuales de x_3 y x_4, precisamente porque su efecto depende conjuntamente de ambas variables).

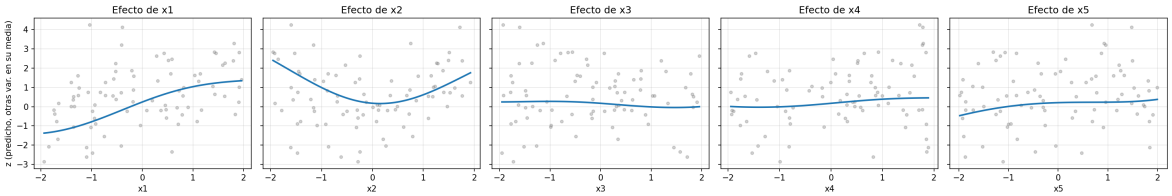


Figura 2: Curvas de dependencia parcial del modelo ajustado para cada una de las cinco variables independientes (con las demás fijas en su media muestral). Los puntos grises son los datos observados, proyectados sobre cada eje.

4.3. Error de entrenamiento vs. error LOOCV: evidencia empírica del sobreajuste

Para ilustrar explícitamente el argumento teórico de la Sección 2.5, se repitió la selección greedy **sin** criterio de parada temprana (forzando la incorporación de los 84 centros disponibles) y con una regularización deliberadamente casi nula ($\lambda = 10^{-8}$), registrando en cada paso tanto $\mathrm{RMSE}_{\mathrm{train}}$ como $\mathrm{RMSE}_{\mathrm{LOOCV}}$. La Figura 3 muestra el resultado en dos escalas: un acercamiento a los primeros 45 centros (panel izquierdo) y el rango completo en escala logarítmica (panel derecho).

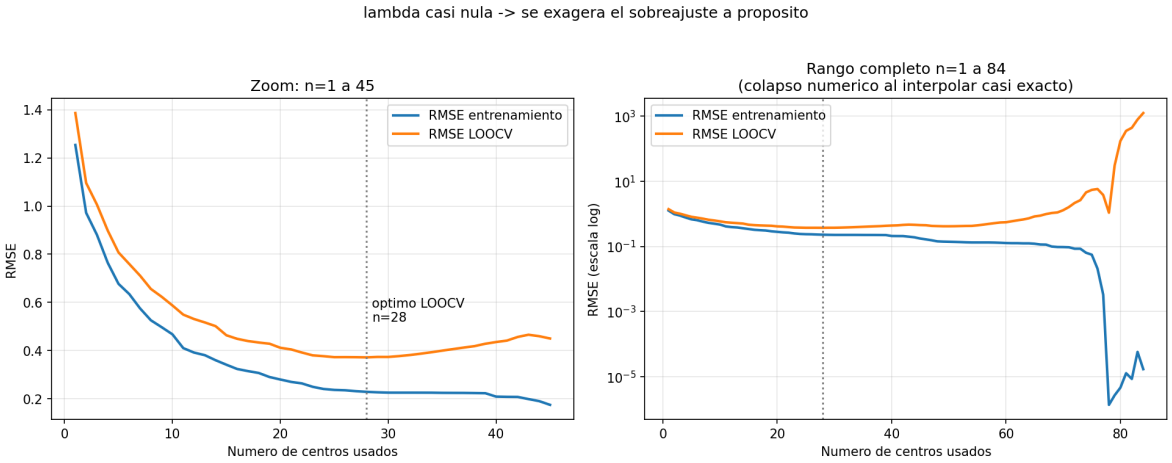


Figura 3: Evolución del error de entrenamiento y del error LOOCV en función del número de centros incorporados, con regularización casi nula ($\lambda = 10^{-8}$) para exagerar deliberadamente el efecto de sobreajuste. El error de entrenamiento decrece monótonamente hasta valores numéricamente nulos ($\sim 10^{-5}$) al aproximarse a la interpolación exacta ($M = N = 84$), mientras que el error LOOCV, tras un mínimo cercano a $M = 28$, crece de nuevo y eventualmente diverge por la casi-singularidad numérica asociada a $h_{ii} \to 1$.

El comportamiento observado es exactamente el previsto por la teoría: el error de entrenamiento es monótono decreciente en la complejidad del modelo, mientras que el error LOOCV exhibe la forma de "U" característica del compromiso sesgo–varianza, con mínimo prácticamente coincidente con el punto de parada temprana identificado por el Algoritmo 1 en la Sección anterior ($M \approx 28$–32, según el nivel de regularización usado).

4.4. Validación numérica de la fórmula de Rippa/Allen

Se verificó la corrección de la implementación de la Sección 2.7 comparando, sobre un subconjunto de $N = 15$ puntos y $M = 15$ centros fijos, el residuo LOOCV calculado (i) analí-

ticamente vía $e_i/(1-h_{ii})$ y (ii) por fuerza bruta (excluyendo explícitamente cada observación, reajustando el modelo con las $N-1$ restantes –manteniendo fijo el conjunto de centros– y evaluando en el punto excluído). Ambos cálculos coincidieron con una diferencia máxima absoluta del orden de 10^{-11}, consistente con el error numérico de punto flotante esperado, lo que confirma la corrección de la derivación de la Sección 2.7 y de su implementación.

Un punto sutil que conviene remarcar es que, en esta verificación por fuerza bruta, al excluir la observación i se elimina únicamente su **ecuación** (la fila correspondiente en $\mathbf{\Phi}$ y $\mathbf{y}$), pero **no** su rol como potencial centro (columna de $\mathbf{\Phi}$): los centros son ubicaciones fijas en el espacio de entrada, independientes de qué subconjunto de ecuaciones se use para ajustar los pesos. Confundir ambos roles –como ocurrió en un primer intento de verificación durante el desarrollo de este trabajo, al eliminar también la columna asociada al punto excluído– produce discrepancias del orden de 10^{-2}–10^{-1} entre el cálculo por fuerza bruta (incorrecto en ese caso) y la fórmula analítica, por estar comparando, de hecho, dos problemas de ajuste distintos.

4.5. Eficiencia numérica: Cholesky vs. inversión explícita

Se comparó el tiempo de cómputo del Algoritmo 2 implementado (i) mediante inversión explícita de A y formación completa de H, y (ii) mediante factorización de Cholesky y sustituciones triangulares (Sección 2.7.3), para distintos tamaños de problema. Los resultados se resumen en la Tabla 1.

Cuadro 1: Tiempo de cómputo por evaluación de modelo (segundos, promedio sobre múltiples repeticiones) para ambos métodos, en función del tamaño del problema.

N (datos)	n_{cols} (centros+cola)	Inversión explícita (s)	Cholesky (s)	*Speedup*
84	35	0.00034	0.00032	1.07×
300	100	0.00164	0.00109	1.51×
1 000	300	0.02691	0.01379	1.95×
3 000	500	0.22928	0.07738	2.96×
8 000	800	2.67004	0.42996	6.21×

A la escala del problema tratado en este trabajo ($N = 84$), la diferencia de tiempo entre ambos enfoques es despreciable (los tiempos están dominados por el costo fijo de las llamadas a las rutinas de álgebra lineal, no por el número de operaciones de punto flotante). La ventaja del enfoque basado en Cholesky se vuelve sustancial únicamente a partir de conjuntos de datos de varios cientos o miles de puntos. No obstante, se adoptó el enfoque de Cholesky como práctica por defecto en la implementación de referencia, por su mayor estabilidad numérica (evita amplificar el número de condición asociado a la inversión explícita), independientemente de la ganancia en velocidad.

5. Estructura de dos niveles del objetivo y estrategia de muestreo de hiperparámetros

Esta sección documenta dos aspectos del diseño que, aunque estaban implícitos en las secciones anteriores, merecen una discusión explícita: (i) la distinción entre la función de pérdida usada para **ajustar** el modelo y el criterio usado para **seleccionarlo**, y (ii) si una alternativa aleatoria o quasi-aleatoria a la búsqueda en grilla empleada originalmente en la Sección 2.9 ofrece alguna ventaja medible para este problema.

5.1. Dos niveles de función objetivo

Todo el procedimiento descrito en las Secciones 2–3 puede describirse, de forma más precisa, como un problema de optimización en **dos niveles**, con un objetivo distinto en cada nivel (Tabla 2).

Cuadro 2: Los dos niveles de función objetivo del procedimiento propuesto.

Nivel	**Qué se decide**	**Función objetivo (*loss*) usada**
Interno (ajuste de parámetros)	Los pesos $\mathbf{w}$, dado un conjunto fijo de centros $\mathcal{S}$ y de hiperparámetros (c, λ)	SSE penalizado (*ridge*): $\|\mathbf{\Phi w} - \mathbf{y}\|^2 + \lambda\|\mathbf{w}_{\text{radial}}\|^2$ — solución cerrada, vía Cholesky (Sección 2.7.3)
Externo (selección de estructura)	Qué centros incorporar (Alg. 1); cuándo detener el greedy; qué c y qué λ usar	$\text{RMSE}_{\text{LOOCV}}$, de forma **consistente** en las tres decisiones

Conviene subrayar que el vector de pesos **w nunca** se ajusta minimizando LOOCV directamente: se ajusta minimizando el SSE penalizado, que admite solución cerrada. Lo que sí es cierto, y es la observación que motiva esta sección, es que **todas las decisiones discretas o estructurales** del procedimiento –qué centro agregar en cada paso del Algoritmo 1, cuándo detenerlo, y qué combinación (c, λ) retener de la búsqueda de hiperparámetros– usan el **mismo** criterio único: $\text{RMSE}_{\text{LOOCV}}$. En ningún punto del procedimiento se usa el error de entrenamiento para tomar una decisión estructural.

Esta arquitectura de dos niveles es estándar en regresión regularizada (por ejemplo, en *ridge* o *lasso*: los coeficientes se ajustan minimizando SSE penalizado para cada λ de una grilla, y λ se elige por validación cruzada). La particularidad del procedimiento aquí propuesto es que ambas decisiones estructurales anidadas –la selección de centros y la de (c, λ)– comparten el mismo criterio de forma consistente, en lugar de usar, por ejemplo, error de entrenamiento para una y LOOCV para la otra (una inconsistencia que puede llevar a que el greedy incorpore centros que el nivel externo deba luego compensar con regularización adicional). Esta consistencia solo es computacionalmente viable gracias a la fórmula de Rippa/Allen (Sección 2.7): sin ella, evaluar $\text{RMSE}_{\text{LOOCV}}$ en cada paso del greedy y en cada punto de la búsqueda de hiperparámetros exigiría un número prohibitivo de reajustes completos del modelo.

Una consecuencia relevante para la sección siguiente es que la superficie de $\text{RMSE}_{\text{LOOCV}}$ en función de (c, λ) –que es precisamente lo que la búsqueda de hiperparámetros explora– **no es suave ni diferenciable**: tiene anidado un proceso combinatorio discreto (el greedy de la Sección 2.8), de modo que pequeños cambios en (c, λ) pueden alterar qué centro se selecciona en algún paso, produciendo discontinuidades. Esta irregularidad es un argumento adicional a favor de estrategias de búsqueda robustas a la falta de suavidad, como las que se comparan a continuación.

5.2. Grid search vs. muestreo aleatorio y quasi-aleatorio

La Sección 2.9 describió la búsqueda de (c, λ) mediante una grilla regular. Cabe preguntarse si un muestreo aleatorio, tipo Monte Carlo, ofrecería alguna ventaja para el mismo presupuesto de evaluaciones.

5.2.1. El argumento de Bergstra & Bengio (2012)

Bergstra y Bengio [12] muestran, con evidencia empírica sobre varios modelos de aprendizaje automático, que para un presupuesto fijo de B evaluaciones sobre d hiperparámetros, una grilla regular produce apenas $B^{1/d}$ valores **distintos** por cada dimensión –las combinaciones de la grilla repiten sistemáticamente las mismas coordenadas en cada eje–, mientras que un muestreo aleatorio produce hasta B valores distintos por dimensión, ya que cada punto se sortea de forma independiente en todos los ejes. La consecuencia práctica es que, sin saber de antemano qué hiperparámetro es más influyente en el desempeño del modelo (su "dimensionalidad efectiva"), el muestreo aleatorio explora mejor cualquier dimensión individual para el mismo costo de cómputo.

Para el caso de este trabajo ($d = 2$: solo c y λ), la ventaja teórica es mucho más modesta que en los casos típicos de la literatura (redes neuronales con 5–10 o más hiperparámetros, donde $B^{1/d}$ se reduce drásticamente). Aun así, la diferencia es cuantificable: la grilla de $15 \times 13 = 195$ evaluaciones usada en la Sección 2.9 produce solo 15 valores distintos de c y 13 de λ; un muestreo aleatorio con el mismo presupuesto produce hasta 195 valores distintos en cada eje –más de 10× la resolución marginal, al mismo costo computacional.

5.2.2. Latin Hypercube Sampling

El muestreo puramente aleatorio, sin embargo, puede producir por azar agrupamientos o vacíos irregulares en el espacio de búsqueda. **Latin Hypercube Sampling** (LHS; McKay, Beckman & Conover, 1979 [13]) es una técnica de muestreo estratificado que conserva la ventaja de resolución marginal del muestreo aleatorio (produce hasta B valores distintos por eje) pero garantiza, por construcción, una cobertura uniforme: cada eje se divide en B intervalos de igual probabilidad y se garantiza exactamente una muestra por intervalo, con lo cual se elimina el riesgo de huecos grandes que sí puede producir el muestreo puramente aleatorio.

La Figura 4 ilustra la diferencia de cobertura marginal entre los tres esquemas –grilla, aleatorio y LHS– para un presupuesto idéntico de 25 evaluaciones en dos dimensiones.

5.3. Comparación empírica sobre el problema propuesto

Para evaluar si esta ventaja teórica se traduce en una mejora medible sobre el problema concreto de este trabajo, se comparó el $\mathrm{RMSE}_{\mathrm{LOOCV}}$ final obtenido por los tres esquemas de búsqueda, con un presupuesto idéntico de 25 evaluaciones (c, λ) para cada uno, sobre el mismo conjunto sintético de validación usado en la Sección 4 y ejecutando, en cada punto evaluado, el procedimiento greedy completo (Algoritmo 1) guiado por la fórmula de Rippa/Allen. Dado que el muestreo aleatorio y LHS dependen de una semilla, cada uno se repitió con 6 semillas distintas; la grilla, al ser determinística, se ejecutó una sola vez. Los resultados se resumen en la Tabla 3.

Cuadro 3: $\mathrm{RMSE}_{\mathrm{LOOCV}}$ final obtenido por cada esquema de búsqueda, con presupuesto idéntico de 25 evaluaciones (c, λ).

Método	Corridas	Mejor	Mediana	Peor
Grilla 5×5 (determinístico)	1		0.30149	
Aleatorio uniforme	6 semillas	0.25849	0.27476	0.32150
Latin Hypercube Sampling	6 semillas	0.28089	0.29724	0.32372

Interpretación. Con el mismo presupuesto computacional, la mediana del muestreo aleatorio mejora el resultado de la grilla en aproximadamente un 9 % (0,27476 vs. 0,30149), y la

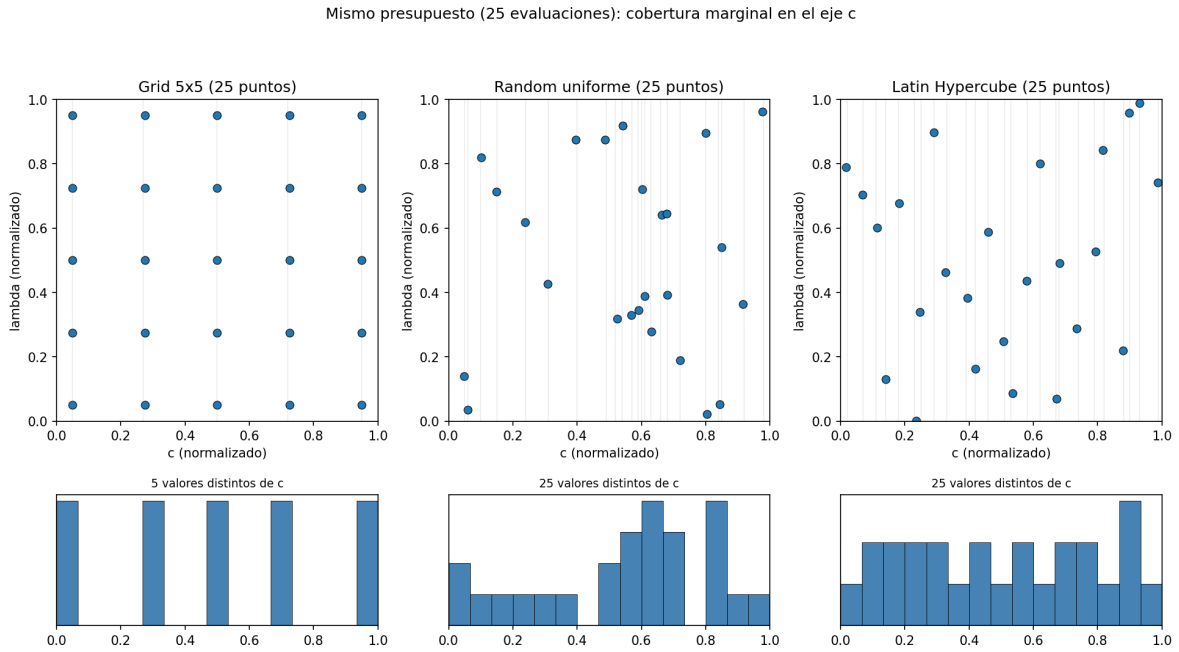


Figura 4: Cobertura del espacio de búsqueda (c, λ), normalizado a $[0, 1]^2$, para el mismo presupuesto de 25 evaluaciones: grilla regular (izquierda), muestreo aleatorio uniforme (centro) y Latin Hypercube Sampling (derecha). El histograma inferior muestra la cobertura marginal del eje c: la grilla produce solo 5 valores distintos, mientras que tanto el muestreo aleatorio como LHS producen los 25 valores distintos posibles –LHS, además, con una distribución marginal visiblemente más uniforme que el muestreo puramente aleatorio.

mediana de LHS lo mejora en aproximadamente un 1,4 % (0,29724 vs. 0,30149). La mejora es real pero modesta, consistente con lo previsto por la teoría para $d = 2$ hiperparámetros (Sección 5.2): la ventaja de random/LHS sobre grilla escala con la dimensionalidad del espacio de búsqueda, y aquí esa dimensionalidad es baja. Con solo 6 semillas, esta comparación no es estadísticamente exhaustiva, pero la dirección del efecto es consistente con la literatura.

Cabe notar que, en esta corrida particular, el muestreo aleatorio puro obtuvo una mediana ligeramente mejor que LHS -algo que la teoría no garantiza en una única comparación con pocas semillas, dado que ambos esquemas tienen variabilidad muestral entre corridas (compárense los rangos [0,258, 0,322] para aleatorio y [0,281, 0,324] para LHS en la Tabla 3).

5.4. Elección final y extensiones futuras

Con base en lo anterior, la implementación de referencia adopta **Latin Hypercube Sampling** como esquema de búsqueda de hiperparámetros por defecto, en lugar de la grilla regular usada en las Secciones 2–4. La elección de LHS por sobre el muestreo puramente aleatorio –a pesar de que este último obtuvo una mediana ligeramente mejor en la comparación empírica anterior– se justifica por una razón estructural antes que por el resultado puntual de una única comparación: LHS garantiza, por construcción, cobertura estratificada del espacio de búsqueda, eliminando el riesgo de que una semilla particular produzca agrupamientos o vacíos grandes por azar (el tipo de variabilidad entre corridas que sí se observa para el muestreo puramente aleatorio en la Tabla 3). Esta modificación se implementó en la clase `RBFApproximator` (método `_sample_hyperparams`), reemplazando los parámetros `c_grid`/`lam_grid` por `c_range`/`lam_range` (los extremos del rango de búsqueda, en escala natural) y `n_search_points` (el presupuesto total de evaluaciones).

Como extensión natural, si el costo por evaluación creciera significativamente (por ejemplo,

al escalar N a varios cientos o miles de puntos, según lo discutido en la Sección 2.7.3), resultaría atractivo migrar a **optimización Bayesiana** [14]: en lugar de muestrear puntos sin usar información previa, se construye un modelo sustituto (típicamente un proceso Gaussiano) sobre los puntos ya evaluados, y se eligen los siguientes puntos maximizando una función de adquisición (p. ej., mejora esperada). Esto típicamente encuentra resultados comparables o mejores con muchas menos evaluaciones que random/LHS/grilla, a costa de mayor complejidad de implementación; no se adoptó en este trabajo dado que, a la escala actual del problema ($N = 84$), el costo total de la búsqueda (minutos) no lo justifica.

6. Limitaciones y recomendaciones

- **Maldición de la dimensionalidad.** Con $N = 84$ observaciones en $d = 5$ dimensiones, la densidad efectiva de muestreo es baja. Los resultados de generalización (estimados por LOOCV) deben interpretarse con cautela, especialmente en regiones del dominio alejadas de los datos observados.
- **Extrapolación.** Aunque la cola polinomial lineal mejora el comportamiento fuera de la envolvente convexa de los datos, no existe garantía de validez de las predicciones en regiones no muestreadas. Se recomienda restringir el uso práctico del modelo al rango observado de cada variable, o acompañar cualquier extrapolación de un análisis de sensibilidad.
- **Multicolinealidad entre variables independientes.** Si dos o más de las cinco variables predictoras están correlacionadas entre sí, la dimensionalidad efectiva del problema es menor a 5, lo cual podría mejorar la calidad del ajuste si se detecta y se tiene en cuenta (por ejemplo, mediante análisis de componentes principales previo).
- **Comparación con modelos alternativos.** Se recomienda contrastar los resultados del modelo RBF con al menos un modelo de referencia más simple (por ejemplo, regresión polinomial de bajo grado) y, si se dispone de tiempo de cómputo adicional, con un proceso Gaussiano (*Gaussian Process Regression*), que modela explícitamente el nivel de ruido mediante un término de *nugget* y provee, de forma natural, intervalos de incertidumbre en la predicción.

7. Conclusiones

Se diseñó e implementó un modelo de aproximación RBF con núcleo multicuádrico adaptado a las condiciones específicas del problema planteado: pocos datos experimentales, alta dimensionalidad relativa y ruido de medición no despreciable. La combinación de regularización de Tikhonov, selección greedy de centros guiada por un estimador analítico de error de generalización (LOOCV, vía la fórmula de Rippa/Allen) y búsqueda en grilla de hiperparámetros permite obtener un modelo que equilibra explícitamente ajuste a los datos y capacidad de generalización, sin requerir un conjunto de validación independiente adicional –algo particularmente valioso dado el tamaño reducido de la muestra disponible.

La validación sobre datos sintéticos con estructura comparable al problema real confirmó: (i) que el criterio de selección basado en LOOCV detiene correctamente la incorporación de centros antes de que el modelo comience a sobreajustarse al ruido; (ii) que la fórmula analítica de LOOCV coincide exactamente con el cálculo por fuerza bruta; y (iii) que la implementación numéricamente estable (Cholesky) reproduce idénticos resultados que el cálculo por inversión explícita, con ventajas de velocidad que se vuelven relevantes solo a mayor escala de datos.

Referencias

[1] Rippa, S. (1999). *An algorithm for selecting a good value for the parameter c in radial basis function interpolation.* Advances in Computational Mathematics, 11(2–3), 193–210.

[2] Chen, S., Cowan, C. F. N., & Grant, P. M. (1991). *Orthogonal least squares learning algorithm for radial basis function networks.* IEEE Transactions on Neural Networks, 2(2), 302–309.

[3] Allen, D. M. (1974). *The relationship between variable selection and data augmentation and a method for prediction.* Technometrics, 16(1), 125–127.

[4] Hoerl, A. E., & Kennard, R. W. (1970). *Ridge regression: Biased estimation for nonorthogonal problems.* Technometrics, 12(1), 55–67.

[5] Tikhonov, A. N., & Arsenin, V. Y. (1977). *Solutions of Ill-Posed Problems.* Winston & Sons, Washington D.C.

[6] Micchelli, C. A. (1986). *Interpolation of scattered data: Distance matrices and conditionally positive definite functions.* Constructive Approximation, 2(1), 11–22.

[7] Buhmann, M. D. (2003). *Radial Basis Functions: Theory and Implementations.* Cambridge University Press.

[8] Hardy, R. L. (1971). *Multiquadric equations of topography and other irregular surfaces.* Journal of Geophysical Research, 76(8), 1905–1915.

[9] Franke, R. (1982). *Scattered data interpolation: Tests of some methods.* Mathematics of Computation, 38(157), 181–200.

[10] Golub, G. H., & Van Loan, C. F. (2013). *Matrix Computations* (4th ed.). Johns Hopkins University Press.

[11] Trefethen, L. N., & Bau III, D. (1997). *Numerical Linear Algebra.* SIAM.

[12] Bergstra, J., & Bengio, Y. (2012). *Random search for hyper-parameter optimization.* Journal of Machine Learning Research, 13, 281–305.

[13] McKay, M. D., Beckman, R. J., & Conover, W. J. (1979). *A comparison of three methods for selecting values of input variables in the analysis of output from a computer code.* Technometrics, 21(2), 239–245.

[14] Snoek, J., Larochelle, H., & Adams, R. P. (2012). *Practical Bayesian optimization of machine learning algorithms.* Advances in Neural Information Processing Systems (NeurIPS), 25.